

IN1097 · Tópicos Avançados em Agentes Inteligentes 2

Introdução à meta-aprendizagem

Aula 2 · 18 de agosto de 2026

Profa. Juscimara G. Avelino

Agenda

- | | | |
|----------|----------------------------------|--|
| 1 | O que é meta-aprendizagem | Definições, meta-conhecimento e a relação com AutoML |
| 2 | De onde vem | De Rice (1976) ao AutoML: o que mudou e por quê |
| 3 | Tipos de problema | AS, HPO, CASH, pipelines, arquiteturas e few-shot |
| 4 | Como se constrói | As duas fases, passo a passo |

Parte 1

O que é meta-aprendizagem

Conjunto	kNN	Árvore	SVM	RF	SVM+PCA
Dados A	0,88	0,81	0,84	0,86	0,80
Dados B	0,62	0,71	0,79	0,77	0,83
Dados C	0,70	0,74	0,72	0,83	0,76

Cada linha é uma tarefa. Cada coluna é uma decisão possível.

O ponto de partida

Não há vencedor universal

Nenhum algoritmo tem o melhor desempenho em todos os conjuntos de dados. Cada um carrega suposições e vieses indutivos diferentes.

A escolha é conhecimento

Um pesquisador experiente escolhe melhor que um iniciante. Esse conhecimento existe — só não está escrito em lugar nenhum.

Logo, é aprendível

Se a escolha depende de características do problema, ela pode ser aprendida a partir de escolhas passadas.

Definição

Meta-aprendizagem é o estudo de métodos que exploram meta-conhecimento para obter modelos e soluções eficientes, adaptando processos de aprendizagem de máquina.

Brazdil, van Rijn, Soares e Vanschoren (2022)

Meta-conhecimento

Informação sobre tarefas anteriores: os dados, os algoritmos e pipelines aplicados e os resultados obtidos.

Também inclui

O conhecimento acumulado durante a busca na própria tarefa atual.

Dois níveis de aprendizado

Nível base

Exemplo	uma linha da tabela
Atributos	as features dos dados
Alvo	a classe ou o valor
Modelo	classificador ou regressor

Meta-nível

Exemplo	uma tarefa/dataset
Atributos	meta-features da tarefa
Alvo	algoritmos, técnicas, hiperparâmetros, desempenho, etc.
Modelo	meta-modelo

Tudo sobre validação, métricas e vazamento vale igual no meta-nível.

Meta-aprendizagem vs AutoML

AutoML abrange todos os aspectos da automatização do processo de aprendizagem de máquina — indo além da seleção de modelo e da otimização de hiperparâmetros.

Guyon, I. et al. Design of the 2015 ChaLearn AutoML challenge. In 2015 IJCNN. IEEE. 2015.

AutoML

É um objetivo: automatizar a construção do modelo de ponta a ponta.

Meta-aprendizagem

É um meio: usar experiência de tarefas anteriores para decidir melhor.

Na prática

Sistemas de AutoML usam meta-aprendizagem para não começar a busca do zero.

Parte 2

De onde vem


Rice (1976): o problema de seleção de algoritmos



Rice mostrou que o desempenho de um algoritmo pode ser relacionado a características mensuráveis da tarefa. Meio século depois, ainda é o mapa da área.

O laço de um sistema de meta-aprendizagem

O meta-modelo sugere; a busca decide se continua



Cada volta do laço custa treinar e avaliar um modelo. O meta-modelo existe para reduzir o número de voltas.

Parte 3

Tipos de problema

Seis famílias de problema

AS

Seleção de algoritmos — escolher, num conjunto discreto, qual usar.

HPO

Otimização de hiperparâmetros — configurar um algoritmo já escolhido.

CASH

As duas coisas ao mesmo tempo: qual algoritmo e com qual configuração.

Síntese de pipeline

Projetar a sequência inteira de etapas, cada uma com sua configuração.

Busca de arquitetura


Generaliza o pipeline: os elementos não precisam estar em sequência.

Few-shot

Aprender uma tarefa nova com poucos exemplos, a partir de tarefas similares.

AS — Seleção de algoritmos

Escolher, num conjunto discreto de candidatos, qual usar



Meus dados



?



Árvore

SVM₁

kNN

SVM₂

Random Forest

conjunto discreto de algoritmos

A saída pode ser um algoritmo — ou, mais útil na prática, um ranking deles.

AS — Seleção de algoritmos

**Imbalanced regression pipeline
recommendation**


*JG Avelino, GDC Cavalcanti, RMO
Cruz - Machine Learning, 2025*

**Meta-Scaler: A Meta-Learning
Framework for the Selection of
Scaling Techniques**

*LBV de Amorim, GDC Cavalcanti, RMO
Cruz - IEEE Transactions on Neural
Networks and Learning Systems, 2024*

HPO — Otimização de hiperparâmetros


O algoritmo já está escolhido; falta configurá-lo



Meus dados



C, gamma,
degree, kernel...



Aqui o espaço é contínuo: não é uma lista de candidatos, é uma região a explorar.


HPO — Otimização de hiperparâmetros

**Combining meta-learning and
search techniques to select
parameters for support vector
machines**

*Gomes, T. A., Prudêncio, R. B., Soares, C., Rossi, A. L.,
& Carvalho, A. - Neurocomputing, 2012*

CASH – Algoritmo e configuração juntos

Combined Algorithm Selection and Hyperparameter optimization



As duas decisões não são independentes: a melhor configuração depende do algoritmo, e o espaço é hierárquico.


CASH — Algoritmo e configuração juntos

**Automated imbalanced
classification via meta-learning**

N Moniz, V Cerqueira - Expert Systems with
Applications, 2021

Workflow (pipeline) synthesis

O objeto da decisão passa a ser a sequência inteira



Cada posição é um CASH, e a ordem entre as etapas também faz parte da decisão.


Workflow (pipeline) synthesis

**MetaML: a multi-label
meta-learning approach for
pipeline recommendation**

CM Maia, LBV de Amorim, GDC Cavalcanti,
RMO Cruz - Machine Learning, 2025

Busca de arquitetura


Generaliza o pipeline: os elementos formam um grafo, não uma fila




Meus dados



Sequencial



Com ramificações




Com blocos repetidos

Exemplo típico: projetar a arquitetura de uma rede neural.

Aprendizagem few-shot

Muitas tarefas grandes e parecidas; uma tarefa alvo com poucos exemplos




Parte 4

Como se constrói

Passos 1 e 2: reunir tarefas e medir

Rodar todos os candidatos em todos os conjuntos



O que seria o alvo? E quais seriam os atributos preditivos?

Tarefa	SVM ₁	SVM ₂	Árv.	RF	kNN
DS1	0,80	0,90	0,75	0,82	0,70
DS2	0,70	0,60	0,80	0,83	0,75
DS3	0,55	0,66	0,65	0,68	0,61
DS4	0,90	0,91	0,92	0,90	0,95
DS5	0,88	0,87	0,80	0,85	0,82

Passo 3: descrever cada tarefa

Meta-features são os atributos do meta-nível

Meta-features típicas

- N° de instâncias e de atributos
- Razão instâncias / atributos
- Entropia das classes
- Assimetria e curtose
- Desempenho de um modelo simples



Tarefa	MF ₁	MF ₂	MF ₃	MF ₄
DS1	500	30	0,30	3,1
DS2	10000	10	0,31	3,1
DS3	760	25	0,45	4,6
DS4	1350	13	0,03	0,9
DS5	158	35	0,80	0,85

Passo 4: juntar as duas metades

Meta-features de um lado, desempenhos do outro

Tarefa	MF ₁	MF ₂	MF ₃	MF ₄
DS1	500	30	0,30	3,1
DS2	10000	10	0,31	3,1
DS3	760	25	0,45	4,6
DS4	1350	13	0,03	0,9
DS5	158	35	0,80	0,85

atributos do meta-nível

+

SVM ₁	SVM ₂	Árvore	RF	kNN
0,80	0,90	0,75	0,82	0,70
0,70	0,60	0,80	0,83	0,75
0,55	0,66	0,65	0,68	0,61
0,90	0,91	0,92	0,90	0,95
0,88	0,87	0,80	0,85	0,82

alvos do meta-nível

Passo 5: definir o alvo e treinar

Três formas de transformar a mesma tabela

Prever o desempenho

0,80 0,90 0,75 ...

Regressor de múltiplas
saídas

Prever o melhor

SVM_2

Classificação multiclasse

Prever o ranking


$SVM_2 > RF > SVM_1 \dots$

Aprendizado de ordenação

Meta-modelo treinado


Passo 6: usar em uma tarefa nova

A fase de recomendação, em quatro movimentos



A arquitetura completa

Uma fase acontece uma vez; a outra, a cada tarefa nova



Para a próxima aula

Tópico 2: seleção de algoritmos e rankings

1 **Ler**

Brazdil et al. (2022), capítulo 2.

Dúvidas: jga2@cin.ufpe.br · material e avisos no SIGAA.