

IN1097 · Tópicos Avançados em Agentes Inteligentes 2

Abordagens de Seleção de Algoritmos (Rankings)

Aula 4

Profa. Juscimara G Avelino

Construindo o ranking

Onde paramos

- Reduzir a informação de performance a um único rótulo **descarta empates, gera ruído e esconde bons concorrentes**
- **Cinco formas de recomendação** e representamos cada uma em diagramas de Hasse
- Decidir quem tem performance comparável ao melhor, via teste estatístico ou margem de tolerância
- **Como o sistema constrói o ranking que recomenda?**

Objetivos

- **Converter** uma matriz de performances em uma matriz de ranks e agregá-la em um ranking único
- **Comparar** os três critérios de agregação e reconhecer quando produzem resultados diferentes
- **Distinguir** as duas abordagens de treinamento de um meta-modelo de ranking

PARTE 3

Criando ranking de modelos para AS

As duas fases

Fase 1 — construção

offline · feita uma vez · cara

- Coletar os metadados: performances e, opcionalmente, meta-características
- Treinar o meta-modelo — que aqui assume a forma de um ranking agregado

Fase 2 — recomendação

online · a cada tarefa nova · barata

- Usar o modelo treinado para recomendar algoritmo(s) para um dataset alvo
- O usuário segue a ordem recomendada até esgotar seu orçamento

Os três passos da Fase 1

1

Avaliar todos os algoritmos em todos os datasets

Validação cruzada de cada algoritmo em cada dataset, preenchendo a matriz de performances P

2

Usar similaridade entre datasets para identificar as partes relevantes dos metadados

Passo opcional — restringe os metadados aos datasets mais parecidos com o alvo

3

Usar todos os resultados para elaborar um ranking de todos os algoritmos

O ranking agregado é, ele próprio, o meta-modelo

A matriz de performances P

- Linhas são datasets: $D = \{d_1, \dots, d_k\}$
- Colunas são algoritmos: $A = \{a_1, \dots, a_n\}$
- Cada célula $P(i, j)$ guarda a performance do algoritmo j no dataset i , após a avaliação correspondente
- Medidas comuns em classificação: acurácia, AUC, F1, microF1 e macroF1

Convertendo P em ranks

A conversão é simples: o melhor algoritmo recebe rank 1, o segundo recebe rank 2, e assim por diante

A conversão é feita linha a linha — dentro de cada dataset, independentemente

Tomemos a linha DS1:

DS1	SVM_1	SVM_2	DT	RF	KNN
Acurácia	0,80	0,90	0,75	0,82	0,70
Rank	3	1	4	2	5

A matriz R completa

Matriz P — performances

DS	SVM_ 1	SVM_ 2	DT	RF	KNN
DS1	0,80	0,90	0,75	0,82	0,70
DS2	0,70	0,60	0,80	0,83	0,75
DS3	0,55	0,66	0,65	0,68	0,61
DS4	0,90	0,91	0,92	0,90	0,95
DS5	0,88	0,87	0,80	0,85	0,82

Matriz R — ranks

DS	SVM_ 1	SVM_ 2	DT	RF	KNN
DS1	3	1	4	2	5
DS2	4	5	2	1	3
DS3	5	2	3	1	4
DS4	4,5	3	2	4,5	1
DS5	1	2	5	3	4

Temos cinco rankings, um por dataset

Como transformá-los em um único ranking recomendado?

Três critérios de agregação

Rank médio (AR)

Variante do método de Borda, inspirado na estatística M de Friedman. Requer, para cada dataset, um ranking de todos os algoritmos

Rank mediano (MR)

Idêntico ao anterior, mas usando a mediana no lugar da média. Menos sensível a um dataset atípico que penalize muito um algoritmo

Vitórias e/ou derrotas significativas

O rank de cada algoritmo leva em conta o número de vitórias significativas sobre os demais — diferenças estatisticamente significativas

O ranking médio (AR)

$$\bar{R}_j = \frac{\sum_{i=1}^n R_{i,j}}{k}$$

- $R_{i,j}$ é o rank do algoritmo base a_j no dataset i
- k é o número de datasets; n é o número de algoritmos
- O ranking final é obtido ordenando os ranks médios e atribuindo novos ranks de acordo

Exemplo

Ranks de 10 algoritmos de classificação em 3 datasets do repositório UCI:

	C5b	C5r	C5t	MLP	RBFN	LD	Lt	IB1	NB	RIP
byzantine	2	6	7	10	9	5	4	1	3	8
isolet	2	5	7	10	9	1	6	4	3	8
pendigits	2	4	6	7	10	8	3	1	9	5

Calculando um rank médio

Tomemos o C5b, primeira coluna:

$$\mathbf{R(C5b)} = (2 + 2 + 2) / 3 = 2,0$$

E o LD, que oscila bastante entre os datasets:

$$\mathbf{R(LD)} = (5 + 1 + 8) / 3 = 4,67$$

O LD foi o melhor em isolet e o oitavo em pendigits. A média esconde essa instabilidade

Todos os ranks médios

	C5b	C5r	C5t	MLP	RBFN	LD	Lt	IB1	NB	RIP
byzantine	2	6	7	10	9	5	4	1	3	8
isolet	2	5	7	10	9	1	6	4	3	8
pendigits	2	4	6	7	10	8	3	1	9	5
Rank médio $R_{\square}$	2,0	5,0	6,7	9,0	9,3	4,7	4,3	2,0	5,0	7,0
Ranking médio	1,5	5,5	7	9	10	4	3	1,5	5,5	8

Ranking recomendado: C5b $\approx$ IB1 $\rightarrow$ Lt $\rightarrow$ LD $\rightarrow$ C5r $\approx$ NB $\rightarrow$ C5t $\rightarrow$ RIP $\rightarrow$ MLP $\rightarrow$ RBFN

Este ranking é o meta-modelo. É ele que orienta os experimentos futuros no dataset alvo

Rank mediano e vitórias significativas

Rank mediano (MR)

- Substitui a média pela **mediana**
- Cachada (2017) comparou AR e MR em 368 workflows sobre 37 datasets
- MR obteve **resultados ligeiramente melhores** — mas a diferença **não foi estatisticamente significativa**
- Vantagem conceitual: **robusto** a um dataset em que o algoritmo vai muito mal

Vitórias significativas

- Uma vitória significativa de a_i sobre a_j é uma diferença de performance estatisticamente significativa
- O rank de cada algoritmo passa a contar quantas vitórias (e/ou derrotas) ele acumula
- Explorado por Brazdil et al (2003) e Leite e Brazdil (2010)
- Custo: exige os testes estatísticos, e portanto a informação por fold

PARTE 3B

Treinando um meta-modelo de ranking

E se quisermos usar meta-características?

O ranking médio ignora o dataset alvo

- O ranking que acabamos de construir é o mesmo para qualquer dataset alvo
- Isso tem uma vantagem: é simples, barato e funciona surpreendentemente bem
- E uma desvantagem: o método segue uma agenda fixa. O dataset alvo não influencia a ordem de teste
- **Para personalizar, precisamos de um meta-modelo treinado sobre meta-características**

O desafio

Um modelo é treinado de acordo com o meta-dataset que lhe é fornecido. A recomendação sairá no mesmo formato do meta-alvo

- Se queremos que o sistema devolva um ranking, o meta-alvo precisa ser compatível com isso
- Há duas maneiras de montá-lo:

Abordagem 1 — prever, depois converter

- **Meta-alvo: a matriz de performances original**
- Treina-se o meta-modelo como um **regressor de múltiplas saídas** para prever as performances
- Em seguida, convertem-se as performances preditas em rankings
- **O modelo aprende a prever números; a ordem é derivada depois**

DS	SVM_1	SVM_2	DT	RF	KNN
DS1	0,80	0,90	0,75	0,82	0,70
DS2	0,70	0,60	0,80	0,83	0,75

Abordagem 2 — prever o ranking direto

- Meta-alvo: a matriz de rankings
- Converte-se a matriz de performances em uma matriz de rankings e usam-se os rankings como meta-alvo
- Treina-se o meta-modelo como um regressor de múltiplas saídas para prever diretamente o ranking
- **O modelo aprende a prever posições; nunca vê as performances absolutas**


DS	SVM_1	SVM_2	DT	RF	KNN
DS1	3	1	4	2	5
DS2	4	5	2	1	3

Qual das duas abordagens deve funcionar melhor?


HARRIS — a abordagem híbrida

- Proposta por Fehring, Hanselle e Tornede (2022)
- **HARRIS: Hybrid ranking and regression forests for algorithm selection**
- Combina as vantagens das duas abordagens e busca mitigar as desvantagens de cada uma
- Um modelo de floresta em que cada árvore é criada com splits otimizados segundo uma função de custo que considera tanto o erro da regressão do ranking quanto o das performances

Fase 1 — treinamento das árvores



Fase 2 — predição para nova instância



$\lambda = 0 \rightarrow$ floresta de regressão pura; $\lambda = 1 \rightarrow$ ranking puro; perdas normalizadas ao intervalo $[0, 1]$.

**Dentre todas as abordagens vistas,
qual será a melhor?**

E como calcular isso?


As abordagens comparadas

Meta-base sintética · 60 datasets · 8 algoritmos · leave-one-dataset-out

método	Spearman	perda no 1º teste	tempo até o ótimo (s)
A1 — performance	0,765	0,030	15,5
HARRIS ($\lambda = 0,3$)	0,737	0,041	15,1
A2 — ranking direto	0,729	0,050	16,5
SW — vitórias significativas	0,240	0,208	25,2
AR — rank médio	0,209	0,296	25,9
MR — rank mediano	0,146	0,208	24,6
Aleatório	-0,018	0,315	50,2

Os três métodos que usam meta-características ficam muito à frente das agregações — que devolvem o mesmo ranking para todo dataset alvo

Curva de perda por número de testes



Seguir a ordem recomendada custa caro no primeiro teste e barato depois — a diferença entre os métodos está quase toda nas duas primeiras posições

Para a próxima aula

Tópico 3: avaliando recomendações

1 **Ler**

Brazdil et al. (2022), capítulo 3.

Dúvidas: jga2@cin.ufpe.br · material e avisos no SIGAA.