

Atividade prática 2

Meta-características específicas do domínio

Objetivo

Na aula vimos quatro famílias clássicas de meta-atributos. Vimos também que não existe conjunto universal: o que vale a pena medir depende da tarefa base, dos algoritmos candidatos e do domínio.

Nesta atividade, o objetivo é **identificar, na literatura, meta-características específicas e potencialmente relevantes para o problema em estudo, incorporá-las ao meta-dataset** da Atividade 1 e avaliar empiricamente se sua inclusão contribui para o desempenho do modelo. A atividade está organizada em duas etapas: um levantamento bibliográfico, que será discutido em aula, e uma etapa experimental, que compõe a entrega.

O meta-dataset é o mesmo da Atividade 1 — mesma matriz P, mesmo protocolo. O que muda é a matriz X. Isso é deliberado: manter tudo o mais constante é o que permite atribuir qualquer diferença observada às novas meta-características.

Calendário

Parte	Data	Entrega
Parte 1 — Levantamento	17/09	Apresentação em aula do quadro de meta-características
Parte 2 — Aplicação	24/09	Relatório com o link do código

Etapa 1 — Levantamento

Procure trabalhos que proponham, adaptem ou avaliem meta-características para o **seu** tipo de problema — dados desbalanceados, multirrótulo, séries temporais, fluxos, recomendação, detecção de anomalias, o que for o seu caso. Selecione os que julgar mais pertinentes e leia-os.

Para cada meta-característica que quiser levar adiante, prepare:

- nome, família a que pertence na taxonomia da aula, e referência;
- o que exatamente se calcula — a definição operacional;
- o que ela pretende capturar;
- por que faz sentido *no seu problema*: que propriedade dos seus dados ela enxerga e as clássicas não;
- custo de extração e se há implementação disponível.

Se o seu problema não tem literatura própria de meta-características, escolha uma direção que a aula não cobriu e trate-a como o seu recorte. Algumas possibilidades: medidas de complexidade baseadas em rede; dureza em nível de instância agregada ao dataset; meta-características aprendidas por codificadores de conjunto, em vez de desenhadas; distâncias entre datasets calculadas diretamente sobre as distribuições; tipologia de exemplos minoritários em problemas desbalanceados; curvas de aprendizado tratadas como objeto, e não como valor final.

Apresentação em aula

A discussão acontece na **quinta, 17 de setembro**. Cada aluno apresenta o seu levantamento, explicando qual é o seu problema, por que as famílias clássicas não bastam para ele, e as meta-características que encontrou — como funcionam e o que medem. Traga os artigos.

A discussão monta um catálogo coletivo: cada um sai da aula com meta-características que não pesquisou pessoalmente. Explicar bem uma medida para os colegas é parte do trabalho, não um extra.

Etapa 2 — Aplicação e análise

Monte agora a matriz X estendida, com duas origens:

- as meta-características **específicas do seu domínio**, levantadas na Parte 1;
- as meta-características **vistas em aula** que você julgar pertinentes ao seu problema — das famílias simples, estatísticas, de teoria da informação, baseadas em modelo, landmarks ou de complexidade.

Bibliotecas como `pymfe`, `ECoL`, `proplexity` e `pyhard` implementam boa parte das medidas clássicas e de complexidade, e poupam reimplementação. Para meta-características específicas do seu domínio, verifique se o artigo disponibiliza código. Não havendo, sugiro implementar.

2.1 Análise com o meta-alvo

Esta é a parte central da atividade. Não basta acrescentar colunas: é preciso mostrar o que elas fazem. Conduza ao menos as três análises abaixo.

1. **Relação com o meta-alvo.** Como cada nova meta-característica se relaciona com a variável que você quer prever — a performance, o rank, o melhor algoritmo. Métodos baseados em árvore no meta-nível fornecem o vetor de importâncias de graça; medidas de associação direta também servem. Se você tem mais de um algoritmo base, examine se o perfil de importância *muda de um para outro*, como em De Amorim et al. (2024), onde cada classificador base depende de famílias diferentes de meta-atributos.
2. **Redundância.** As novas colunas trazem informação nova ou repetem o que as clássicas já diziam? Correlação entre meta-características, agrupamento das redundantes, ou eliminação reversa — escolha um instrumento e aplique-o.

- 3. Efeito no sistema de recomendação.** Reexecute as abordagens da Atividade 1 com $X_{\text{estendido}}$ e compare com os resultados obtidos com X_{base} , sob o mesmo protocolo *leave-one-dataset-out* e as mesmas métricas — correlação de Spearman, curva de perda e sua área. Apresente a comparação em um gráfico de diferença crítica.

Dimensionalidade. Seu meta-dataset tem poucas dezenas de linhas. Dobrar o número de colunas de X não é um gesto neutro — é exatamente o cenário em que a aula disse que a seleção deixa de ser opcional. Um resultado pior com $X_{\text{estendido}}$ é um resultado legítimo, e provavelmente o mais interessante de discutir.

3 Entrega

Um **relatório de no máximo cinco páginas**, contendo o **link para o código** — repositório, notebook público ou equivalente, com as saídas executadas e acessível sem solicitação de permissão. A tabela do levantamento entra em anexo e não conta contra o limite de páginas.

O relatório deve cobrir:

- 1. O levantamento.** Que problema você trata, que meta-características encontrou, de que trabalhos, e por que elas fazem sentido nesse problema. Quais você conseguiu extrair e quais ficaram de fora, com o motivo — indisponibilidade de implementação, custo, incompatibilidade com os seus dados.
- 2. Os resultados.** As três análises da Seção 2.1, com o custo de extração registrado.
- 3. A interpretação.** O que as novas meta-características revelaram sobre o seu problema; se o sistema de recomendação melhorou, piorou ou ficou igual, e o que explica isso; se o ganho, havendo algum, compensa o custo de extração; e o que você levaria dessa análise para a sua pesquisa.

A interpretação é a parte que mais pesa. Um relatório que mostra ganho sem explicar de onde ele vem vale menos que um que mostra ausência de ganho e argumenta por quê.