

Atividade prática

Meta-dataset e ranking de algoritmos

Objetivo

Construir um meta-dataset e usá-lo para comparar as abordagens de seleção de algoritmos vistas em sala. Cada aluno trabalhará com o *seu próprio* meta-dataset. O ideal é que ele tenha relação com a sua pesquisa — o domínio de aplicação da sua dissertação ou tese, o conjunto de bases com que você já trabalha, o problema que você já está tentando resolver.

1 O meta-dataset

Um meta-dataset é composto por dois objetos:

- **P**, a matriz de performances — uma linha por dataset, uma coluna por algoritmo;
- **X**, a matriz de meta-características — uma linha por dataset, uma coluna por descritor do dataset.

Origem dos dados. Você pode montar **P** e **X** a partir do OpenML, de outro repositório público, de resultados que você mesmo executou, ou de um meta-dataset já existente na literatura. Se você já tem um meta-dataset da sua pesquisa, use-o. Qualquer que seja a origem, ela deve estar descrita no relatório com detalhe suficiente para que outra pessoa entenda o que a matriz representa.

Dimensões sugeridas. Ao menos 30 datasets e ao menos 5 algoritmos. Se o seu contexto de pesquisa impuser menos datasets, prossiga — mas reconheça a limitação ao interpretar os resultados.

1.1 A matriz de performances **P**

Escolha uma medida de performance adequada ao seu problema (acurácia, F1, AUC, RMSE, o que fizer sentido) e mantenha-a consistente em toda a matriz. Diga qual usou e por quê.

Guarde a performance por fold. O critério de *vitórias significativas* (Seção 2.1c) exige um teste estatístico pareado, e portanto o valor *de cada fold* — não a média. Se você está recuperando resultados de um repositório, verifique se a consulta devolve resultados por fold; no OpenML isso corresponde ao parâmetro `per_fold=True` em `list_evaluations`. Se você mesmo está executando os experimentos, salve os folds. Sem esse dado você não conseguirá fazer aquele item.

Se você recuperar resultados de um repositório, a matriz provavelmente sairá **esparsa**: nem todo algoritmo foi executado sobre todo dataset. Você precisará descartar linhas e/ou colunas até obter uma matriz completa.

1.2 As meta-características X

Apesar de ainda não termos visto a aula sobre meta-características, vocês já têm uma noção geral do que são. Basta extrair as disponíveis, não se espera aqui um critério formal de seleção. Não há uma lista obrigatória. Escolha os descritores que você acha que fazem sentido para o seu problema. As famílias abaixo servem de ponto de partida; os nomes entre parênteses são os das *qualities* do OpenML, para quem estiver usando aquela fonte.

- **Gerais / de dimensão.** Número de instâncias, de atributos, de classes; atributos numéricos, simbólicos e binários; contagem de valores faltantes. (NumberOfInstances, NumberOfFeatures, NumberOfClasses, NumberOfNumericFeatures, NumberOfSymbolicFeatures, NumberOfBinaryFeatures, NumberOfMissingValues, Dimensionality.)
- **Balanceamento de classes.** Proporção e tamanho das classes majoritária e minoritária. (MajorityClassPercentage, MinorityClassPercentage, MajorityClassSize, MinorityClassSize.)
- **Estatísticas.** Médias, desvios, assimetria e curtose dos atributos numéricos. (MeanMeansOfNumericAtts, MeanStdDevOfNumericAtts, MeanSkewnessOfNumericAtts, MeanKurtosisOfNumericAtts.)
- **Teoria da informação.** Entropia das classes e dos atributos, informação mútua, razão sinal-ruído. (ClassEntropy, MeanAttributeEntropy, MeanMutualInformation, EquivalentNumberOfAtts, NoiseToSignalRatio.)
- **Derivadas.** Razões e transformações que você calcula a partir das anteriores — instâncias por atributo, proporção de faltantes, proporção de atributos simbólicos, log das contagens brutas. Se usar, dê a fórmula.
- **Específicas do seu domínio.** Se a sua pesquisa sugere descritores que nenhuma lista genérica contempla, use-os — e explique o raciocínio.

1.3 A matriz de ranks R

Converta P na matriz de ranks R, com rank 1 = melhor e empates recebendo rank médio. R será usada tanto pelas abordagens de agregação quanto como rótulo de algumas das abordagens treinadas.

2 As abordagens

Implemente e aplique as seis abordagens abaixo.

2.1 Agregação de rankings (meta-modelo = ranking fixo)

1. **AR** — rank médio: média dos ranks por coluna de R, depois re-ranqueia.
2. **MR** — rank mediano: idem, com mediana.
3. **Vitórias significativas** — Para cada par de algoritmos e para cada dataset, utilize um teste estatístico pareado sobre os resultados obtidos nos folds. Considere uma vitória quando a diferença for estatisticamente significativa e favorecer o algoritmo

avaliado. Utilize o teste de Wilcoxon signed-rank, com nível de significância α definido no relatório.

2.2 Meta-modelos treinados (usam X)

4. **Abordagem 1** — regressor de múltiplas saídas treinado sobre P; as performances preditas são convertidas em ranking depois.
5. **Abordagem 2** — regressor de múltiplas saídas treinado sobre R; prediz as posições diretamente.
6. **HARRIS** — floresta híbrida, em que cada split é escolhido por uma combinação convexa de duas perdas: $L = \lambda L_{\text{ranking}} + (1 - \lambda) L_{\text{regressão}}$. Implemente as duas perdas e a combinação, e rode com $\lambda \in \{0; 0,25; 0,5; 0,75; 1\}$.

3 Avaliação experimental

Em modo *leave-one-dataset-out*, calcule para cada abordagem:

1. **Correlação de Spearman** entre o ranking recomendado e o ranking verdadeiro do dataset deixado de fora, com média sobre as rodadas.
2. **Curva de perda por número de testes**: seguindo a ordem recomendada, calcule a perda após t testes como a diferença entre a melhor performance possível no dataset e a melhor performance obtida entre os t primeiros algoritmos testados. Para métricas em que **maior é melhor**, $\text{perda}_i(t) = \max_j P_{ij} - \max_{a \in \text{primeiros } t} P_{ia}$. Para métricas em que **menor é melhor**, inverta a ordem da diferença. Reporte a curva média de perda e a área sob a curva, calculada como a média das perdas para $t = 1, \dots, m$.
3. **Gráfico de diferença crítica**: comparando as seis abordagens. Use o teste de Friedman seguido do pós-teste de Nemenyi, com o resultado apresentado no diagrama de diferença crítica.

4 Entrega

Um **relatório de no máximo três páginas**, contendo o **link para o código** — repositório, notebook público ou equivalente.

O relatório deve cobrir três coisas:

1. **Descrição do meta-dataset e do problema que ele resolve**. De onde vêm os dados, quais datasets e algoritmos o compõem, quais meta-características você usou, e — principalmente — que pergunta de seleção de algoritmos esse meta-dataset permite responder.
2. **Resultados**. As métricas da Seção 3 para as seis abordagens, incluindo o efeito do λ no HARRIS. Tabelas e figuras são bem-vindas.
3. **Interpretação**. O que os números dizem. Onde as abordagens discordaram e por quê; se as abordagens treinadas superaram as agregações e o que no seu meta-dataset explica isso.